

PWAI Projekt

Kacper Sojda

February 4, 2026

1 Konsolidacja danych

Dane ze strony IMGW zostały pobrane za pomocą bibliotek **BeautifulSoup**, która została wykorzystana do zparsowania HTML i wyszukania linków do plików ZIP, oraz **requests**, która służy do pobierania plików ze stron internetowych. Pliki w formacie .zip trafiły do folderu "imgw_zips".

Następnie do rozpakowania plików została użyta biblioteka **zipfile** oraz **re** która przefiltrowała pliki, za pomocą matchingu, zostawiając tylko te interesujące nas. Pliki w formacie .csv trafiły do folderu "imgw_csv".

Ostatnim krokiem, było połączenie plików CSV w jeden, oraz zostawienie tylko potrzebnych kolumn.

Została utworzona tablica zawierająca wszystkie nazwy kolumn według dokumentacji IMGW. Oraz druga tablica z nazwami interesujących nas kolumn, która posłużyła jako maska odfiltrowująca niepotrzebne dane.

Na sam koniec za pomocą pętli wszystkie pliki zostały przefiltrowane oraz połączone w jeden plik csv o nazwie "imgw_2001_2023_.csv".

Cały kod odpowiedzialny za konsolidację danych znajduje się w "download.py"

2 Proste charakterystyki i statystyki danych

Cały kod odpowiedzialny za wykonanie zadań znajduje się w "main.py". Pierwszym elementem było pobranie złączonego pliku .csv do df

2.1 Stacje z pełną historią

Rekordy z df zostały pogrupowane na podstawie nazwy stacji a następnie zliczone. Następnie nazwy wszystkich stacji posiadających 8400 rekordów, czyli pełnej historii zostały umieszczone w osobnym pliku "stacje_mające_8400_rekordów.csv". Takich stacji jest 28.

2.2 Miesięczna ilość pomiarów dla stacji z niepełną historią

Po raz kolejny rekordy zostały pogrupowane, tym razem jednak wybrano stacje nie posiadające 8400 rekordów a następnie została wybrana pierwsza z nich.

Następnie wzięto rekordy zawierające tylko nazwę tej stacji i pogrupowano je na podstawie roku oraz miesiąca, posortowano i przedstawiono na wykresie 1.




Figure 1: BABIMOST

Wykres zawiera dane tylko od marca 2013 roku, gdyż do tego czasu stacja nie wysyłała żadnych danych.

2.3 Średnia temperatura dla stacji z pełną historią

Wybrano tutaj prostrzą wersję i założono że każdy miesiąc ma dokładnie 31 dni.

Użyto tych samych technik jak w podpunktach 2.1 oraz 2.2 i stworzono df składający się z rekordów pierwszej stacji z pełną historią.

Następnie stworzono nową kolumnę "Dni od startu" która została policzona na podstawie daty i reprezentuje ona ile minęło dni od "dnia 0".

Na koniec stworzono wykres 2, przy pomocy kolumn "Dni od startu" i STD.




Figure 2: BIAŁOWIEŻA

2.4 Minimalna i maksymalna temperatura

Skopiowano `df` a następnie usunięto z niego rekordy nie zawierające `TMIN` i `TMAX`,

Następnie przy pomocy funkcji `"idxmin()"` znaleziono index wiersza z najmniejszą temperaturą minimalną i wyciągnięto ten record za pomocą funkcji `"loc()"`.

```
min_temp_row = df4_temp.loc[df4_temp["TMIN"].idxmin()]
```

Analogicznie dla temperatury maksymalnej.

Wyniki:

Temperatura minimalna: -37.3 C 08.01.2017 JABŁONKA

Temperatura maksymalna: 39 C 08.08.2015 CEBER

2.5 Średnia temperatura miesięczna dla stacji z pełną historią

Wykorzystano tutaj wcześniej utworzony `df` dla stacji BIAŁOWIEŻA

Usunięte zostały rekordy niezawierające średniej temperatury, Następnie pozostałe zostały pogrupowane na podstawie roku i miesiąca i wyciągnięto z nich średnią.




Figure 3: Styczeń




Figure 4: Luty




Figure 5: Marzec




Figure 6: Kwiecień




Figure 7: Maj




Figure 8: Czerwiec




Figure 9: Lipiec




Figure 10: Sierpień




Figure 11: Wrzesień




Figure 12: Październik




Figure 13: Listopad




Figure 14: Grudzień